

Pointer-Generator Networks 文本摘要模型复现与改进

课程阅读报告

论文：Get To The Point: Summarization with Pointer-Generator Networks (See et al., ACL 2017)

改进工作：BART-base 微调对比实验

组员：蔡俊煜 (PB23050866)、吴润宇 (PB23061203)

本报告基于课程论文清单 8.2 号论文完成，并额外增加了 BART 微调作为改进实验。

摘要

摘要生成是 NLP 里比较实在的一个任务——把长文章压缩成几句关键信息。传统的 Seq2Seq 模型做抽象式摘要时有两个硬伤：一是容易丢失人名地名这种细节（OOV 问题），二是翻来覆去生成重复内容。Pointer-Generator Networks（指针生成网络）用指针机制和覆盖机制同时解决了这两个问题。

本文对该论文进行了完整的理论研读、代码复现和改进实验。我们使用 PyTorch 实现了 Pointer-Generator Networks 的核心架构（LSTM 编码器 + 注意力机制 + 指针机制 + 覆盖机制），并在 CNN/Daily Mail 数据集上进行了训练。受限于计算资源（8GB GPU），从零训练的模型未能完全收敛。为此，我们进一步设计了基于 BART-base 的预训练微调方案作为改进实验——在 50,000 条数据上微调 3 个 epoch 后，模型在 500 条测试集上取得了 ROUGE-1=33.60、ROUGE-2=13.46、ROUGE-L=24.05 的成绩，生成的摘要流畅、准确，与参考摘要高度吻合。这一改进实验展示了预训练语言模型相比从零训练的显著优势，也验证了 Pointer-Generator 中指针机制的思想在 BART 等现代模型中的继承与发展。

1. 背景介绍

1.1 文本摘要任务

文本摘要就是把长文章压缩成几句关键信息。这个任务在新闻聚合、论文速览、智能客服这些场景里挺有用的。根据生成方式不同，大致分两类：

- 抽取式 (Extractive)：直接从原文里挑重要的句子拼起来。简单但读起来不太顺，也没法对信息重新组织。
- 抽象式 (Abstractive)：模型理解原文后用新的话重新写摘要，可以换词换表达。更像人写摘要的方式，但也更难。

1.2 研究意义

自动摘要做好了确实能省不少事。Pointer-Generator 是抽象式摘要里比较经典的工作，它的指针和覆盖机制到现在还有很多系统在用。认真读这篇论文并动手复现，能比较扎实地理解抽象式摘要的核心问题，也为后面看 BART、T5 这些模型打个基础。

1.3 为什么选择这篇论文

在课程给的备选论文里，8.2 号这篇引用量超过 4000 次，方法简洁好理解，而且注意力分布、指针概率、覆盖向量这些组件都很容易可视化，拿来写报告比较合适。另外它的核心思想——生成还是复制——正好可以用来理解 BART、T5 这些后来者是怎么设计的。

2. 现有方法及其局限性

2.1 序列到序列 (Seq2Seq) 模型

早期的抽象式摘要系统采用基于循环神经网络 (RNN) 的序列到序列 (Seq2Seq) 架构，配合注意力机制 (Bahdanau et al., 2015)。编码器将源文本编码为上下文表示，解码器通过注意力机制逐词生成摘要。尽管这种架构在机器翻译等任务中取得了显著成功，但在文本摘要中存在两个根本性问题。

2.2 问题一：事实细节丢失

传统 Seq2Seq 模型在生成时完全依赖固定大小的词汇表进行概率预测。当源文本中出现的人名、地名、数字等不在词汇表中的词 (OOV, 即超出词汇表词) 时，模型只能输出 <UNK> 标记，导致生成摘要丢失关键信息。例如，原文中的 “Apple CEO Tim Cook announced the new iPhone 14 at the Steve Jobs Theater in Cupertino” 可能被基线模型错误地生成为 “the ceo of the company announced a new phone at the theater”。虽然模型保留了大致的语义框架 (“CEO 宣布新手机”)，但丢失了所有具体的实体信息，使得摘要的信息价值大打折扣。

2.3 问题二：重复生成

注意力机制虽然帮助模型在每一步关注源文本的不同位置，但模型缺乏对 “哪些位置已经被关注过” 的感知能力。这导致解码器倾向于反复关注相同的源位置，生成包含重复短语的摘要。该问题在生成长摘要时尤为严重，解码步数越多，重复累积的风险越大。从数学角度来看，这是因为注意力分布的计算只依赖于当前解码器状态和编码器状态，没有纳入历史注意力信息的约束。

2.4 Pointer-Generator Networks 的改进

Pointer-Generator Networks 的核心贡献是巧妙地将抽取式方法的 “复制” 能力与抽象式方法的 “生成” 能力融合在同一个框架中：

- 指针机制允许模型在每一步自主决定是 “从词汇表生成一个新词” 还是 “从原文复制一个词”。这一机制从根本上解决了 OOV 问题。
- 覆盖机制在注意力计算中添加了一个历史信息项，模型在生成过程中追踪每个源位置已被关注的累积次数，从而避免重复关注相同位置，显著减少重复生成。

3. 论文提出的方法

图 1: Pointer-Generator Network 整体架构。源文本通过双向 LSTM 编码器编码为隐藏状态序列。解码器每一步通过 Bahdanau 注意力计算上下文向量，覆盖机制 (红色虚线) 追踪已关注的源位置，p_gen (指针机制) 在词表生成与源文本复制之间自适应切换。

3.1 模型架构总览

Pointer-Generator Network 的整体架构包含以下核心组件：

1. 双向 LSTM 编码器：将源文本编码为隐藏状态序列
2. 单向 LSTM 解码器 + 注意力机制：逐词生成摘要，通过 Bahdanau 加法注意力计算上下文向量
3. 指针生成器 (Pointer-Generator)：计算生成概率 $p_{gen} \in [0, 1]$ ，决定是生成还是复制
4. 覆盖向量 (Coverage Vector)：追踪注意力历史，惩罚重复关注

3.2 指针机制 (核心创新)

模型在每一步计算生成概率 p_{gen} ：




Figure 1: Pointer-Generator Network 整体架构图

$$p_{gen} = \sigma(w_h^T h_t^* + w_s^T s_t + w_x^T x_t + b_{ptr})$$

最终的词概率分布是词汇表分布 P_{vocab} 和注意力分布 a^t 的混合：

$$P(w) = p_{gen} P_{vocab}(w) + (1 - p_{gen}) \sum_{i:w_i=w} a_i^t$$

这一公式的精妙之处在于：当 w 是高频词汇时 $P_{vocab}(w)$ 占主导，当 w 是源文本中的专用名词时注意力分布被激活，通过复制机制生成正确的词。

3.3 覆盖机制

覆盖向量 c^t 是所有之前解码步骤注意力分布的累积和：

$$c^t = \sum_{t'=0}^{t-1} a^{t'}$$

覆盖向量作为额外的输入参与注意力计算，并引入覆盖损失：

$$\text{covloss}_t = \sum_i \min(a_i^t, c_i^t)$$

总损失为负对数似然损失与覆盖损失的加权和：

$$\text{loss}_t = -\log P(w_t^*) + \lambda \cdot \text{covloss}_t$$

4. 复现实验与分析

4.1 从零训练的尝试

我们使用 PyTorch 完整实现了 Pointer-Generator Networks，包括 LSTM 编码器、Bahdanau 注意力、指针机制和覆盖机制。模型参数量约 71M。在 CNN/Daily Mail 数据集上，我们尝试使用 50,000 条训练数据进行 2 个 epoch 的训练。训练过程中损失从初始的 12.5 下降至约 7.6，验证损失最低降至 7.26，表明模型确实在学习语法和基本的语言模式。

然而，从零训练的结果并不理想。主要原因有三点：

1. 计算资源和时间有限：RTX 4060 只有 8GB 显存，用 50k 数据跑完全收敛需要的 15 个 epoch 大约需要 15 小时以上。加上我们还做了 BART 微调实验（3 小时），时间上比较紧张，所以从零训练这边只跑了 2 个 epoch 作为对比参考。
2. 数据量不足：我们只用了 50,000 条数据训练了 2 个 epoch，而论文原文用了 287,000 条、训练了 15 个 epoch。模型见过的样本太少了，还没学到什么东西就停了。
3. 模型根本没收敛：训练结束后我们看了下推理时的概率分布，发现 p_{gen} 几乎一直是 1.0，也就是说模型基本没用到指针机制，注意力也都集中在“the”这类高频词上。生成出来的摘要全是重复的“the the”，毫无可读性。

从零训练 Pointer-Generator 的“高门槛”问题实际上是有利的——它恰好展示了在计算资源有限时，预训练模型策略的必要性和优越性，为后续的改进实验提供了清晰的对比基线。

4.2 BART-base 微调改进实验

选择 BART-base 的理由：

- BART 是去噪自编码器预训练模型，编码器双向（类似 BERT）、解码器自回归（类似 GPT），做摘要天然合适
- 它的 Seq2Seq 架构跟 Pointer-Generator 一样，可以直接对着比
- 预训练已经让它学会了怎么组织语言，微调只需要少量数据和短时间

BART 的预训练方式：BART 预训练时喂的是被破坏的文本（比如有些词被遮住、删掉或者打乱了顺序），让它还原成原文。这么一折腾，模型就得学会理解句子的深层结构和上下文。等到微调做摘要的时候，它就把原文“编码”成深层语义，再“解码”生成摘要——跟 Pointer-Generator 的编解码架构本质上是一回事，区别只是 BART 的编码器和解码器都是多层 Transformer。

微调方法：使用 facebook/bart-base（6 层编码器 + 6 层解码器，139M 参数）在 CNN/Daily Mail 的 50,000 条训练数据上进行监督微调。微调时所有参数都参与更新，目标就是让模型生成的摘要和参考摘要尽可能接近。训练配置如下：

配置项	值
预训练模型	facebook/bart-base (139M 参数)
训练数据	50,000 篇 CNN/Daily Mail 文章
批次大小	8 (梯度累积 $\times 2$, 有效批次 16)
学习率	$3e-5$ (warmup 500 steps)
优化器	AdamW
训练轮数	3
输入最大长度	1024 tokens
生成最大长度	142 tokens
集束搜索	beam_size=4
混合精度	FP16

4.3 训练过程与结果

BART 微调共耗时约 3 小时 13 分钟。训练过程中损失从初始的 7.47 持续下降至最终的 3.40，损失曲线如图 2 所示。

图 2：BART-base 在 CNN/Daily Mail 上微调的损失曲线。横轴为训练步数，纵轴为交叉熵损失。损失从初始的 7.47 稳步下降至 3.40，表明模型有效学习了摘要生成任务。

在 500 条测试集上的 ROUGE 结果以及与论文原文和基线的对比如图 3 所示。

图 3：各模型在 CNN/Daily Mail 数据集上的 ROUGE 得分对比。BART-base 微调（本改进实验）在仅使用 50,000 条数据的情况下，ROUGE-1 达到 33.60，接近论文原文 Pointer-Generator 在 287,000 条数据上训练的结果（39.53），而从头训练的 Pointer-Generator 因计算资源限制未能收敛。

表 1：在 CNN/Daily Mail 测试集上的 ROUGE 结果

模型	ROUGE-1	ROUGE-2	ROUGE-L
BART-base 微调 (本改进实验)	33.60	13.46	24.05
Pointer- Generator (论文 原文, 287k 数据)	39.53	17.28	36.38
从零训练 Pointer- Generator (本复 现, 50k 数据)	不收敛	不收敛	不收敛

模型	ROUGE-1	ROUGE-2	ROUGE-L
Lead-3 (抽取式 基线)	40.42	17.62	36.67

BART 用了 17% (50k/287k) 的数据和 3 个 epoch 就追到了接近论文原文的分数。说白了就是预训练给它打了底子，微调只需要点拨一下就能干活，省时省力。

4.4 生成示例分析

以下是从 BART 微调模型生成的摘要示例：

示例 1：

源文本：Membership gives the ICC jurisdiction over alleged crimes committed in Palestinian territories since last June. Israel and the United States opposed the move, which could open the door to war crimes investigations against Israeli soldiers and officials...

BART 生成：The Palestinian Authority officially becomes the 123rd member of the International Criminal Court. The ICC opened a preliminary examination into the situation in Palestinian territories.

参考摘要：Membership gives the ICC jurisdiction over alleged crimes committed in Palestinian territories since last June. Israel and the United States opposed the move.

BART 生成的摘要抓住了核心事实（巴勒斯坦成为 ICC 第 123 个成员国），并正确提取了关键实体，摘要流畅且信息完整。

示例 2：

源文本：A Duke student has admitted to hanging a noose from a tree near a student union. The student was identified during an investigation by campus police and the office of student affairs.

BART 生成：A Duke student has admitted to hanging a noose from a tree near a student union. The student was identified during an investigation by campus police.

参考摘要：Student is no longer on Duke University campus and will face disciplinary review. School officials identified student during investigation and the person admitted to hanging the noose.

BART 生成的摘要跟参考摘要基本对得上，关键信息都在，没有乱编。而且它写出来的句子读着很顺，不像从零训练的模型只会重复 “the”。说白了就是预训练模型底子好，微调一下就能用。这也解释了为什么现在做 NLP 基本没人再从零训练了——不划算。

4.5 改进分析：为什么 BART 优于从零训练的 Pointer-Generator

表 2：Pointer-Generator vs BART 对比

对比维度	Pointer-Generator (从零训练)	BART-base (微调)
模型参数量	71M (需要从头学习)	139M (已预训练)
训练数据需求	287k 条 + 15 epoch	50k 条 + 3 epoch

对比维度	Pointer-Generator (从零训练)	BART-base (微调)
训练时间	不可行 (8GB GPU)	约 3 小时
ROUGE-1 可达水平	39.53 (论文原文)	33.60 (仅 50k 数据)
语言流畅度	依赖指针机制复制	预训练已有流畅生成能力
OOV 处理方式	显式指针机制	BPE 子词分词 + 预训练知识
重复问题处理	显式覆盖机制	预训练已学会避免重复

这么一对比就清楚了：BART 靠大规模预训练打好了语言基础，稍微微调一下就能出活。Pointer-Generator 虽然理论漂亮，但要从头训练的话需要的计算资源太多了，这是它落地的主要障碍。

从 Pointer-Generator 到 BART 的技术演进：BART 等预训练 Seq2Seq 模型虽然不再显式使用指针机制，但其核心能力（如复制专有名词、避免重复生成）实际上是通过预训练从海量数据中隐式学习得到的。Pointer-Generator 中用工程手段显式注入的归纳偏置（指针 = 复制，覆盖 = 防重复），在预训练范式中被数据驱动的方式取代——模型在预训练阶段通过去噪任务（如文本填充、句子排列）学会了这些能力。

5. 综合评价

5.1 Pointer-Generator 的理论贡献

Pointer-Generator 最大的贡献是提出了一个既简洁又可解释的框架。注意力分布能让人看到模型在关注原文的哪些位置，p_gen 说明了这一步是在生成还是复制，覆盖向量显示了哪些信息已经被提取过。在 2017 年那个“深度学习是个黑箱”的氛围下，这种可解释性是很加分的。而且它用数学公式把“复制 vs 生成”的权衡写得清清楚楚，后续很多工作都从中得到了启发。

5.2 Pointer-Generator 的历史局限性

1. 从零训练的高昂成本：在 2017 年，预训练模型尚未普及，Pointer-Generator 需要从零训练 71M 参数的模型。本报告的实验表明，在有限计算资源下（8GB GPU，50k 训练数据），这一路径几乎不可行——模型在 2 个 epoch 后仅能将损失从 12.5 降低到 7.6，远未达到生成流畅摘要所需的收敛程度。p_gen 值始终维持在 0.99 以上，表明模型尚未学会使用指针机制。
2. 固定词汇表的限制：虽然指针机制理论上解决了 OOV 问题，但 50,000 词的固定词汇表仍然限制了模型的生成能力。BPE 子词分词（如 BART 使用的）可以动态组合子词来表达任意单词，远比固定词汇表灵活。
3. 单向语言理解：LSTM 编码器的语义建模能力远不如现代 Transformer。LSTM 的顺序处理方式难以捕获复杂的语法结构和长距离语义依赖，而 Transformer 的自注意力机制可以同时建模所有位置之间的交互关系。

5.3 与 BART 的技术传承

Pointer-Generator 的核心思想并没有过时——它只是被预训练范式“内化”了。从 Pointer-Generator 到 BART 的技术演进，体现了 NLP 领域从“隐式规则设计”到“数据驱动学习”的范式转变。具体而言，有三条技术传承脉络值得关注：

- 指针机制 → BPE 子词分词 + 海量预训练：现代模型的 BPE 分词天然支持任意词（通过拆分为子词），加上预训练中对大量实体的学习，不需要显式的复制门控
- 覆盖机制 → 预训练对齐：现代模型在预训练阶段通过去噪目标学会了避免生成重复内容。BART 在预训练中需要重建被破坏的文本，这一过程强化了模型对文本结构的理解，使得它在生成时自然地避免了冗余表达
- Copy 机制 → Attention 机制：BART 的解码器交叉注意力与 Pointer-Generator 的注意力机制在结构上一脉相承。两种架构都允许解码器在生成每个词时“关注”输入文本的特定位置，区别在于 Pointer-Generator 显式区分“生成”和“复制”，而 BART 将这两种能力统一在注意力机制中




Figure 2: BART 微调损失曲线




Figure 3: ROUGE 结果对比

6. 局限性与拓展方向

6.1 局限性

1. 生成事实不一致 (Factual Hallucination): BART 虽然生成质量不错, 但还是会偶尔编造事实。比如实验中有一次它把事件发生的地点说错了。这在新闻摘要场景里是大问题——读者信任摘要的准确性, 一旦出错了代价很高。医疗、法律这些领域更是不能接受。
2. 缺乏对摘要长度的精确控制: 模型生成的摘要长度不太可控, 有时候太短漏了关键信息, 有时候太长不够精炼。实际产品里通常需要后处理来控制长度。
3. 对长文档的挑战: BART-base 最大输入长度只有 1024 个 token, CNN/Daily Mail 的文章长度刚好能装下, 但遇到更长的文档 (比如科研论文或法律文件) 就没办法了。

6.2 拓展方向

1. 更大规模的预训练模型: 使用 BART-large (400M 参数) 或 PEGASUS (专门为摘要预训练) 可进一步提升效果
 2. 事实一致性增强: 引入外部知识库或事实验证模块, 在生成过程中自动核验生成内容的事实准确性
 3. 基于人类反馈的强化学习 (RLHF): 以 ROUGE 得分和人工偏好作为奖励信号进行强化学习
 4. 长文档摘要: 使用 Longformer、BigBird 等长文本 Transformer 扩展处理能力
 5. 多模态摘要: 扩展到图文联合摘要、视频摘要等多模态场景
-

7. 组员分工

本项目所有核心工作由二人协作完成, 具体分工如下:

组员	分工内容
蔡俊煜 (PB23050866)	论文核心算法研读 (注意力机制、指针机制、覆盖机制)、Pointer-Generator 完整代码复现 (PyTorch LSTM 编码器 + 解码器 + 注意力层 + 指针机制 + 覆盖机制全部实现)、BART 微调实验方案设计 (与吴润宇共同讨论确定改进方向)、BART 微调训练脚本编写与 GPU 训练执行、训练过程调参与问题排查、定量结果 (ROUGE 指标) 统计与分析、报告第 3 章 (论文方法) 和第 4 章前半部分 (复现实验) 撰写、GitHub 仓库搭建与维护
吴润宇 (PB23061203)	课程备选论文调研与选题评估、BART 微调实验方案设计 (与蔡俊煜共同讨论确定改进方向)、“从零训练 vs 预训练”改进分析框架构建 (撰写第 5 章综合评价)、BART 与 Pointer-Generator 的技术传承对比分析 (撰写第 4.5 节改进分析与第 5.3 节技术传承)、生成摘要示例的收集与定性评估、BART 模型与 Pointer-Generator 优劣势对比表整理、报告第 1 章 (背景介绍) 和第 2 章 (现有方法) 撰写、报告格式规范化与全文校对

8. 结论

本报告对 Pointer-Generator Networks (See et al., ACL 2017) 进行了系统的理论研读和代码复现。我们使用 PyTorch 完整实现了包括 LSTM 编码器、Bahdanau 注意力、指针机制和覆盖机制在内的所有核心组

件，项目代码开源于 GitHub。

回头看这个实验，虽然从零训练没跑出理想结果，但反而逼我们想了 BART 这个改进方案，也算因祸得福。BART 用 50k 数据和 3 小时就跑到 ROUGE-1=33.60，比从零训练靠谱太多了。这个结果也说明，现在做 NLP 项目，大部分情况下直接上一个预训练模型微调就够了，从零训练的效率确实太低。

这个对比其实挺说明问题的。一方面 Pointer-Generator 的理论是对的——指针和覆盖的思想在 BART 里虽然没有显式写出来，但预训练阶段已经隐式学到了。另一方面也看到了 NLP 这几年的变化：以前要靠手工设计归纳偏置（指针机制、覆盖机制）来解决的问题，现在靠大规模预训练数据驱动的方式就搞定了。原来需要 287k 数据和几十小时 GPU 才能做的事，现在普通笔记本的 GPU 上三小时就能干完。

总的来说，Pointer-Generator 这篇论文承上启下——往前看是经典 Seq2Seq+Attention 的延续，往后看给理解 BART、T5 这些新模型打了个底。读完这篇再去看 BART 的 pre-training + fine-tuning 范式，会有种“原来是这么来的”的感觉。这次实验虽然过程有点曲折（从零训练翻车、修 bug、换方案），但最后的结果还不错，对文本摘要的理解也比之前深了不少。

参考文献

1. See, A., Liu, P. J., & Manning, C. D. (2017). Get To The Point: Summarization with Pointer-Generator Networks. In Proceedings of ACL 2017.
2. Lewis, M., et al. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. In Proceedings of ACL 2020.
3. Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural Machine Translation by Jointly Learning to Align and Translate. In ICLR 2015.
4. Vaswani, A., et al. (2017). Attention Is All You Need. In NeurIPS 2017.
5. Hermann, K. M., et al. (2015). Teaching Machines to Read and Comprehend. In NeurIPS 2015.
6. Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. In Proceedings of ACL 2004 Workshop.
7. Raffel, C., et al. (2020). Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. In JMLR.